

ANN 및 전이학습 기반 소재(물성) 대응 FDM 공정 품질 예측 모델 개발

Development of an ANN and Transfer Learning-Based Quality Prediction Model in the Fused Deposition Modelling (FDM) Process

최성빈¹, 김병찬¹, 서재원¹, 안창균¹, 신혜원², 조웅현², 이상원^{1#}
Seongbin Choi¹, Byeong Chan Kim¹, Jaewon Seo¹, Changgyun Ahn¹, Hyewon Shin², Unghyeon Cho² and Sang Won Lee^{1#}

¹ 성균관대학교 기계공학부 (School of Mechanical Engineering, Sungkyunkwan University)

² 성균관대학교 기계공학과 (Department of Mechanical Engineering, Sungkyunkwan University)

Corresponding Author / E-mail: sangwonl@skku.edu, TEL: +82-31-290-7467

KEYWORDS: 3D 프린팅 (3D Printing), Fused Deposition Modeling Process (융합수지압출적층공정), Artificial Intelligence (인공지능), Quality Prediction (품질 예측), Process Optimization (공정 최적화), Composite Materials (복합소재)

3D 프린팅 기술은 다양한 산업 분야에서 활용되고 있으며, 그 중에서도 Fused deposition modelling (FDM)은 다양한 형상 제작과 우수한 기계적 강도를 제공하고 복합소재를 활용한 제품 생산이 가능하여 경량화 및 고기능화를 추구하는 고부가가치 산업에서 특히 주목받고 있다. 그러나 FDM 공정에는 다양한 공정변수가 존재하고 이들 변수간의 상호작용에 의해 다양한 품질이 나타난다. 이를 위해 공정 최적화 연구가 수행되고 있으나, 현재 수행되는 연구들은 주로 단일 소재에 초점을 맞춘 최적화 방법론에 집중하고 있어 복합소재 적용을 위한 혼합비별 공정 최적화에는 빠른 대응이 어렵다는 한계가 있다. 이에 본 연구에서는 이러한 문제를 해결하기 위해 FDM 공정의 대표 소재 2 가지를 활용하여 ANN 기반의 품질 예측 모델을 구축하고 이를 사전학습 모델로 활용하여 매우 적은 데이터로 제 3 의 소재 물성을 예측할 수 있는 전이학습 기반의 소재(물성) 대응 품질 예측 모델을 구축하였다. 이를 위해 ABS 와 PLA 를 대표 소재로 선정하고, 이 두 소재의 특성을 중간 값으로 갖는 PETG 를 전이학습을 위한 제 3 의 소재로 선정하였다. 먼저, ABS, PLA, PETG 소재를 사용하여 FDM 공정 데이터를 수집하고 이렇게 얻은 ABS 및 PLA 데이터를 활용하여 오차율 3.60%의 ANN 기반 사전학습 모델을 구축하였으며, 해당 모델과 전이학습을 활용하여 오차율 5.68%의 PETG 소재 품질 예측 모델을 개발하였다. 본 연구의 결과는 FDM 공정의 다양한 소재 적용과 최적화에 있어 보다 효율적인 방법론을 제시하며, 향후 3D 프린팅 공정을 활용한 최적 소재(물성) 최적화에도 응용될 수 있을 것으로 기대된다.

1. 서론

3D 프린팅 공정은 CAD 데이터로부터 형상 정보를 획득하고 이를 바탕으로 소재를 층별로 쌓아 올려 3 차원 구조물을 제작하는 공정이다. 그 중 열가소성 플라스틱을 재료로 하여 제품을 생산하는 대표적인 플라스틱 3D 프린팅 공정인 Fused deposition modelling (FDM)은 지지대 (Support)를 함께 출력하여 복잡한 형상 제작이 가능하고, 열을 기반으로 소재의 상태를 변화시키고 이를 층별 증착함으로써 우수한 기계적 강도를 갖는 제품을 제작할 수 있다¹. 또한, 해당 공정에서는 열가소성 소재뿐만 아니라 여러 소재가 합성 (Compounding) 된 복합소재

필라멘트를 활용한 제품 생산 역시 가능하여 높은 형상 자유도가 요구되는 자동차 산업, 항공/우주와 같은 고부가가치 산업에서의 경량화 및 고기능화 구현을 위한 대표 제조공정으로 채택되고 있다².

이러한 FDM 공정을 산업에 적용하기 위해서는 적절한 공정변수 선정을 통해 치수 정확도 및 기계적 강도의 향상, 공정 시간 및 재료의 감소 등의 제품 및 공정 목표 달성이 필요하다². 이를 위하여 FDM 공정에서의 최적화를 위한 다양한 연구가 수행되고 있는데, Torres³ 등은 레이어 두께, 인필(Infill) 밀도 등의 FDM 공정변수에 따른 PLA 부품 특성을 분석하고 ANOVA 기반의 다목적 최적화를 수행하였고, Deswal⁴

등은 FDM 의 치수 정확도를 향상시키기 위해 ANN-GA 를 활용하여 레이어 두께, 적층 방향 등에 따른 ABS 소재 부품에 대한 품질 최적화를 수행하였다.

그러나, 이와 같은 FDM 공정 최적화 연구는 단일 소재에 국한되고 있으며, 이는 앞서 서술한 바와 같이 복합재료가 적용될 경우 개발 과정에서 변경되는 소재 혼합비에 따라 매번 새로운 최적화 과정을 수행하여야 한다는 한계가 존재한다. 특히, 복합소재는 합성되는 원 소재의 비율에 따라 무수히 많은 조합이 가능하여 많은 시간과 비용이 소요되기 때문에 이에 대한 보다 효율적인 공정 최적화 방안 도출이 필요하다. 이에 본 연구에서는

FDM 공정에 다양한 소재를 적용함에 있어 원소재를 기반으로 구축된 품질 예측 모델을 활용하여 보다 적은 데이터로도 제 3 의 소재에 대한 품질을 예측할 수 있는 전이학습 기반의 소재(물성) 대응 FDM 공정 품질 예측 모델을 개발하였다. 본 연구를 위하여 원소재로 ABS 와 PLA 소재를 활용하였으며, 소재(물성) 대응을 위한 제 3 의 소재로 두 소재의 중간 소재에 해당하는 PETG 를 선정하고 활용하였다. 먼저, 2 장에서는 이러한 소재를 활용한 FDM 공정 데이터 수집 및 분석에 대하여 서술하였으며, 3 장에서는 ABS 와 PLA 소재 데이터를 활용한 사전학습 모델을 구축하고, 구축된 사전학습 모델 및 전이학습을 활용한 PETG 대응 품질 예측 모델을 구축하였다. 또한 해당 장에서는 여러 모델의 결과를 비교함으로써 최종적으로 구축된 소재(물성) 대응 모델에 대한 성능을 평가하였다.

2. FDM 공정 데이터 수집 및 분석

2.1 활용 소재

본 연구에서의 소재(물성) 대응 품질 예측을 위한 재료로서 ABS, PLA 그리고 PETG 가 활용되었다. ABS 와 PLA 는 다양한 색상과 높은 해상도의 인쇄가 가능하여 3D 프린팅 공정에 적용되는 가장 대표적인 소재이다. 특히, ABS 의 경우에는 높은 강도와 내열성을 갖는다는 장점으로 주로 산업용 제품이나 자동차 부품 제조와 같은 분야에서 사용되고 있으며, PLA 는 ABS 에 비해 친환경적이고 저렴하여 주로 개인용 3D 프린팅 업체 및 교육기관에서 사용되고 있다. 그러나 최근 산업에서는 앞서 서술한 바와 같이 단일 소재를 넘어 경량화 및 고기능화를 위한 복합소재 개발 및 공정 연구가 진행되고 있다. 이에 본 연구에서는 복합재료의 대안으로 ABS 와 PLA 의 중간 성격을 갖는 PETG 소재를 제 3 의 소재로 선정하였으며, ABS 와 PLA 소재를 사전학습을 위하여 그리고 PETG 소재를 전이학습을 통한 소재(물성) 대응을 위하여 활용하였다. 특히, 물성이 고려된 품질 예측 모델 구축을 위하여 6 가지 물성치가 함께 적용되었으며, 활용된 소재별 물성치는 표 1 과 같다.

Table 1 Materials properties

	ABS	PLA	PETG
Density (g/cm ³)	1.10	1.24	1.23
Thermal resistance (W/mK)	87	59	76
Impact strength (kJ/m ²)	14	4	8
Glass transition temperature (°C)	60	105	85
Thermal conductivity (W/mK)	0.1	0.183	0.2
Linear thermal expansion coefficient (1/K)	12*10 ⁻⁵	8.5*10 ⁻⁵	8*10 ⁻⁵

2.2 실험 환경 및 설계

공정 데이터 수집을 위한 FDM 적층 실험은 그림 1 의 Ultimaker 社의 2+를 활용하여 수행 되었다. 우선, 실험 설계를 위하여 문헌조사를 통해 가장 대표적인 FDM 적층 품질과 그에 가장 큰 영향을 미치는 변수를 탐색하였으며, 그 결과 표 2 와 같이 베드 온도, 노즐 온도, 레이어 두께의 3 가지 변수를 공정변수로, 치수, 인장강도 및 중량의 3 가지 품질을 관찰변수로 선정하였다.

실험은 ABS, PLA, PETG 의 3 가지 소재에 대하여 각각 수행되었으며, 본실험을 수행하기 전 사전실험을 진행하여 각 소재별 적절한 변수 범위를 탐색하고 그 범위 내에서 2 또는 3 수준으로 나누어 완전요인배치법을 통해 실험이 설계되었다. ABS 와 PLA 는 3 요인 3 수준으로 설계되었으며, 27case 에 대하여 5 회 반복 실험되어 각각 135 개 (총 270 개) 데이터가 수집되었다. PETG 의 경우에는 더 적은 데이터로 소재(물성) 대응 품질 예측 모델을 구축하기 위하여 3 요인 2 수준의 8 개 case 에 대하여 3 회 반복 실험하여 총 54 개 데이터가 수집되었다.


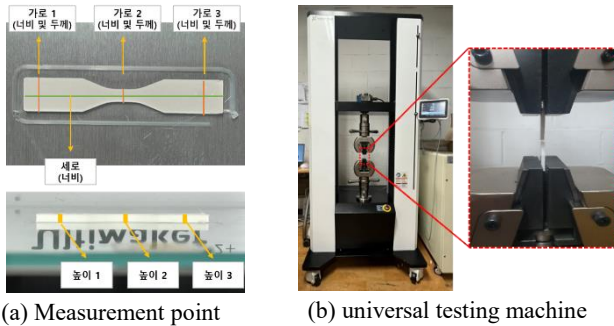


Fig. 1 The photo of the Fused deposition modelling machine

2.3 공정 데이터 수집

공정 데이터는 공정조건별 ASTM D638 Type V 규격의 인장시편을 출력하고 해당 시편의 치수와 인장강도를 측정함으로써 수집되었다. 이때, 전체적인 치수에 대한 정확도를 나타내기 위하여 그림 2-(a)에 표시된 시편의 7 군데에서 치수를 측정하고 CAD 파일 대비 발생된 오차의 비율을 모두 평균한 것을 치수 정확도로서 나타내었다. 인장강도는 그림 2-(b)와 같이 테스트원 社의 만능재료 시험기인 UNITEST M2-10 을 사용하여 인장시험을 수행하고 이를 통해 측정된 응력-변형률 곡선(Stress-Strain curve)으로부터 계산되었으며, 중량은 전자저울을 이용하여 측정되었다.



(a) Measurement point

(b) universal testing machine

Fig.2 The photo of the dimension measurement point and the universal testing machine

이러한 과정을 통해 수집된 FDM 공정 데이터의 수는 표 2 와 같으며, 3 장에서 구축될 각각의 모델에 대하여 소재별 학습 및 테스트 데이터로 분할 및 사용되었다.

Table 2 Number of data collected and training/test data sets

Model	Material	Train data	Test data	Total
Pre-trained	ABS	108	27	135
	PLA	108	27	135
	Total	216	54	270
Transfer learning	PETG	16	8	24

3. 소재(물성) 대응 FDM 공정 품질 예측 모델 개발

3.1 ANN 기반 사전학습 모델 구축

소재(물성) 대응 전이학습 모델 구축을 위하여 사전학습 모델로써 인공 신경망 (Artificial Neural Network, ANN) 기반 ABS 및 PLA 에 대한 품질 예측 모델이 구축되었다. ANN 은 비선형 데이터의 예측을 위한 대표적인 AI 방법론으로 순전파 및 역전파 학습 알고리즘을 통해 복잡한 패턴의 데이터를 효과적으로 학습할 수 있다는 장점이 있다. 따라서 본 연구에서는 비선형적이고 복잡한 패턴의 소재별 물성 및 강도 데이터 예측을 위해 해당 방법론을 활용하여 ABS+PLA 소재에 대한 사전학습 모델을 구축하였다.

사전학습 모델 구축을 위하여 ABS 와 PLA 의 5 cycle 데이터가 사용되었으며, 이는 8:2 로 분할하여 표 2 와 같이 각각 학습 및 테스트에 사용되었다. 구축된 사전학습 모델은 그림 3 과 같이 3 개의 은닉층 (Hidden layer), 3 개의 공정변수와 6 개의 물성치로 구성된 9 개의 입력층 (Input layer), 그리고 예측하고자 하는 품질인 3 개의 출력층 (Output layer)으로 구성되었으며, 비선형성 함수인 ReLU 를 활성화 함수로

사용하여 Adam optimizer 를 통해 학습되었다. 또한, 모델 성능 향상을 위하여 그리드 서치(Grid search)를 통한 최적의 하이퍼 파라미터 탐색이 표 3 과 같이 수행되었으며, 최적 하이퍼 파라미터로 Learning rate = 0.01, No. of N1 = 30, No. of N2 = 30, No. of N3 = 10 이 선정되었다.




Fig.3 Structure of ANN-based pre-learning model

Table 3 Hyper parameters of pre-trained model

Hyper parameters	Value
Epoch	10,000
Learning rate	0.001, 0.005, 0.01
No. of neuron in 1st hidden layer	20, 30, 40
No. of neuron in 2nd hidden layer	10, 20, 30
No. of neuron in 3rd hidden layer	5, 10, 15, 20

모델의 성능은 치수 정확도, 인장강도, 중량 각각에 대하여 발생된 오차율을 계산하고 이들에게 동일한 가중치를 부여하고자 3 개 품질에 대한 평균 오차를 평가하였다. 단 이때, 인장강도와 중량의 경우 오차율 계산을 위해 평균절대비오차 (Mean Absolute Percentage Error, MAPE)가 계산되었으며, 치수 정확도의 경우 이미 단일 지표화 과정에서 평균 오차가 고려되었으므로 평균 절대 오차(Mean Absolute Error, MAE)로 계산되었다. 이러한 모델 성능 평가 결과 평균 오차 3.60%의 성능이 평가되었다.

3.2 전이학습 기반 소재(물성) 대응 품질 예측 모델 구축

소재(물성) 대응 품질 예측 모델 구축을 위하여 3.1 장에서 구축된 사전학습 모델을 사용한 전이학습 기반 PETG 품질 예측 모델이 구축되었다. 전이학습을 위한 학습 데이터로는 사전학습 데이터의 수보다 상대적으로 매우 적은 3 cycle 의 데이터가 활용되었으며, 이를 2:1 의 비율로 분할하여 표 2 와 같이 학습 및 테스트 데이터로 사용되었다.

구축된 전이학습 모델의 성능 향상을 위하여 그림 4 와 같이 최적의 재학습 레이어 탐색이 수행되었으며, 그

결과, 표 4 와 같이 3 번째 은닉층 (Hidden layer 3)과 분류기 (Classifier)만 재학습된 Model 2 가 5.68%의 오차로 가장 높은 성능을 보였다.




Fig.4 Fine tuning for each transfer learning model

Table 4 Performance results for each transfer learning model

Model	Fine-tuning	Error (%)
Model 1	Hidden layer 2 +Hidden layer 3 + Classifier	5.81
Model 2	Hidden layer 3 + Classifier	5.68
Model 3	Classifier	6.01

4. 결론

본 연구에서는 인공지능 기반의 대표적인 예측 모델인 ANN 모델과, 전이학습 기법을 활용해 상대적으로 적의 데이터 수로도 충분한 정확도의 확보가 가능한 FDM 공정 소재(물성) 대응 예측 모델을 구축하였다. 먼저, ABS, PLA, PETG 의 3 가지 소재에 대하여 베드 온도, 노즐 온도, 레이어 두께를 공정변수로 하는 FDM 공정 실험을 수행하여 ASTM D638 Type V 규격의 인장시편을 출력하였으며, 해당 시편으로부터 치수 정확도, 인장강도, 중량을 측정함으로써 공정변수에 따른 FDM 품질 데이터를 수집하였다.

이후 ABS 와 PLA 데이터 (Train 216 / Test 54)를 활용하여 ANN 기반의 사전학습 모델을 구축하였으며, 그리드 서치를 수행하여 최적의 하이퍼 파라미터를 탐색 및 선정함으로써 오차율 3.60%의 강건한 사전학습 모델을 구축하였다. 이렇게 구축된 ABS 및 PLA 품질 예측 모델을 PETG 예측을 위한 전이학습 모델의 사전학습 모델로 활용하였으며, 상대적으로 적은 PETG 데이터 (Train 16 / Test 8)를 전이학습을 위한 재학습 데이터로 활용하고 Fine-tuning 을 수행하여 가장 성능이 우수한 전이학습 조건을 탐색하였다. 그 결과, 3 번째 은닉층 (Hidden layer 3)과 분류기 (Classifier)만 재학습된 Model 2 가 오차율 5.68%로 가장 우수한 성능을 보였다.

이러한 결과는 총 24 개라는 극히 적은 PETG 데이터 셋으로도 사전학습 모델과 근소한 성능 차이를 보이는

강건한 소재(물성) 대응 품질 예측 모델이 구축되었음을 알 수 있다. 이는 경량화 및 고기능화 추구를 위해 복합소재 개발 연구가 수행되고 있는 자동차 산업 등에서 소재-공정 동시설계 연구를 위해 활용될 수 있으며, 더 나아가 본 연구의 모델에서 입력 데이터로 물성치를 고려함으로써 목표 품질 달성을 위한 소재의 물성치를 역으로 제안하는 최적화의 기능으로도 활용될 수 있다.

향후에는 보다 충분한 학습 데이터를 확보하여 더 강건한 사전학습 모델과 전이학습 모델을 구축하고자 하며, 사전학습을 위한 데이터 셋의 수를 차등 적용하여 PETG 단일 모델과 유사한 성능을 나타내기 위한 전이학습 모델의 최소 학습 데이터 셋의 수를 확인하고자 한다. 또한, PETG 외의 복합재료에서의 적용 가능성을 확인하고, FDM 공정에서의 목표 품질 달성을 위한 적용 소재의 물성치를 제안하는 소재-공정 최적화 모델을 구축하고자 한다.

ACKNOWLEDGEMENT

This work was supported by the Technology Innovation Program (20013794, Center for Composite Materials and Concurrent Design) funded by the Ministry of Trade, Industry & Energy (MOTIE, Korea) and by the National Research Foundation of Korea (NRF) grant funded by the Korea government (MSIT) (No. 2022R1A2C3012900)

REFERENCES

1. Anketa Jandyal et al., "3D printing - A review of processes, materials and applications in industry 4.0", Sustainable Operations and Computers, Vol. 3, pp. 33-42, 2022
2. Ravikumar Patel et al., "A review article on FDM process parameters in 3D printing for composite materials", Materials Today: Proceedings, Vol. 60, No. 3, pp. 2162-2166, 2022
3. Jonathan Torres et al., "Mechanical Property Optimization of FDM PLA in Shear with Multiple Objectives", The Minerals, Metals & Materials Society (TMS), Vol. 67, pp. 1183-1193, 2015
4. Sandeep Deswal et al., "Modeling and parametric optimization of FDM 3D printing process using hybrid techniques for enhancing dimensional preciseness", International Journal on Interactive Design and Manufacturing (IJIDeM), Vol. 13, pp. 1197-1214, 2019

**Seongbin Choi**


B.Sc. candidate in the School of Mechanical Engineering, Sungkyunkwan University.
E-mail: cosogi@g.skku.edu

**Sang Won Lee**

Professor in the School of Mechanical Engineering, Sungkyunkwan University. His research interest is smart manufacturing, sustainable manufacturing, and data-driven design
E-mail: sangwonl@skku.edu

**Byeong Chan Kim**

B.Sc. candidate in the School of Mechanical Engineering, Sungkyunkwan University.
E-mail: kbc7952@g.skku.edu

**Jaewon Seo**

B.Sc. candidate in the School of Mechanical Engineering, Sungkyunkwan University.
E-mail: na06219@g.skku.edu

**Changgyun Ahn**

B.Sc. candidate in the School of Mechanical Engineering, Sungkyunkwan University.
E-mail: keum5223@naver.com

**Hyewon Shin**

Ph.D. candidate in the Department of Mechanical Engineering, Sungkyunkwan University. Her research interest is smart and sustainable manufacturing
E-mail: cinewon@g.skku.edu

**Unghyeon Cho**

M.Sc. candidate in the Department of Mechanical Engineering, Sungkyunkwan University. His research interest is smart and sustainable manufacturing
E-mail: manufacho17@g.skku.edu